

МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ

Національний технічний університет

«Київський політехнічний інститут»

Навчально-науковий комплекс

«інститут прикладного системного аналізу»

Кафедра штучного інтелекту

КУРСОВА РОБОТА

з дисципліни

«Методи та технології напівкерованого навчання»

на тему: **«Гібридні напівкеровані випадкові дерева із активним навчанням»**

Виконала:
студентка 5-го курсу
групи КІ-41мп
Харитонova С. В.

Перевірів:
д.т.н проф. Синєглазов В.М.
Оцінка _____
«__» _____ 2024 р.

м. Київ – 2025 рік

ЗМІСТ

ВСТУП.....	3
РОЗДІЛ 1. ОГЛЯД АЛГОРИТМІВ ПОВ'ЯЗАНИХ РОБІТ.....	4
1.1 Напівконтрольоване активне навчання з тимчасовою розбіжністю результатів.....	5
1.2. Активний напівконтрольований випадковий ліс для класифікації гіперспектральних зображень.....	9
РОЗДІЛ 2. ІНТЕГРАЦІЯ TOD/COD З ASSRF ДЛЯ КЛАСИФІКАЦІЇ ГІПЕРСПЕКТРАЛЬНИХ ЗОБРАЖЕНЬ.....	14
РОЗДІЛ 3. ОПИС ТА АНАЛІЗ ОТРИМАННИХ РЕЗУЛЬТАТІВ.....	20
3.1. Набір даних Botswana.....	20
3.2. Набір даних Kennedy Space Center (KSC).....	21
3.3. Результати на наборі даних Botswana.....	23
3.3.1 Базові методи класифікації.....	23
3.3.2 Продуктивність TOD/COD-ASSRF.....	24
3.3.3 Детальний аналіз результатів класифікації.....	27
3.4. Результати на наборі даних Kennedy Space Center.....	31
3.4.1. Базові методи класифікації.....	31
3.4.2 Продуктивність TOD/COD-ASSRF.....	32
3.4.3. Детальний аналіз результатів класифікації.....	34
ВИСНОВКИ.....	39
СПИСОК ВИКОРИСТАНИХ ДЖЕРЕЛ.....	41

ВСТУП

Сучасні задачі обробки даних, зокрема класифікація гіперспектральних зображень, вимагають ефективних алгоритмів, здатних працювати з великими обсягами інформації за умов обмеженої кількості маркованих даних. Напівкероване навчання, яке поєднує марковані та немарковані дані, є перспективним напрямом для підвищення точності класифікації при зниженні витрат на анотування. У поєднанні з активним навчанням, що оптимізує вибір найінформативніших зразків для маркування, такі методи відкривають нові можливості для вирішення складних задач, таких як аналіз гіперспектральних даних.

Актуальність цієї проблеми зумовлена зростаючим попитом на автоматизовану обробку даних у сферах дистанційного зондування, екології, сільського господарства та інших галузях, де гіперспектральні зображення є ключовим джерелом інформації.

Метою курсової роботи є розробка гібридного алгоритму напівкерованого навчання на основі випадкових дерев з активним навчанням для класифікації гіперспектральних даних.

Завдання роботи включають:

- аналіз літератури та переклад та опрацювання ключових джерел;
- формування аналітичної постановки задачі;
- синтез модифікованого алгоритму з використанням темпоральної похибки активного навчання;
- реалізація алгоритму та тестування на реальних даних.

Об'єктом дослідження є процес класифікації гіперспектральних зображень, а предметом – гібридні алгоритми напівкерованого навчання на основі випадкових дерев із застосуванням активного навчання.

Проблема напівкерованого навчання активно досліджується як у міжнародному, так і в національному науковому просторі. У міжнародній практиці значний внесок зроблено такими роботами, як Zhang et al. (2019), де розглянуто застосування напівкерованих випадкових лісів для класифікації гіперспектральних даних, та Huang et al. (2021), які запропонували використання темпоральної похибки в активному навчанні. У національному контексті дослідження в цій галузі зосереджені переважно на адаптації подібних методів до локальних задач, таких як аналіз сільськогосподарських даних чи моніторинг довкілля, однак систематичних розробок гібридних алгоритмів із активним навчанням поки що недостатньо. Ступінь вивченості теми є високим у міжнародній науці, але в Україні такі дослідження перебувають на етапі становлення, що підкреслює актуальність і новизну роботи.

Робота має як теоретичне, так і практичне значення. Теоретично вона поглиблює розуміння гібридних підходів у напівкерованому навчанні, а практично – пропонує алгоритм, який може бути застосований для обробки гіперспектральних даних у реальних задачах. Актуальність дослідження підтверджується його спрямованістю на вирішення сучасних викликів у сфері машинного навчання та аналізу даних.

РОЗДІЛ 1. ОГЛЯД АЛГОРИТМІВ ПОВ'ЯЗАНИХ РОБІТ

1.1 Напівконтрольоване активне навчання з тимчасовою розбіжністю результатів

Стаття, опублікована на конференції ICCV, представляє інноваційний підхід до активного навчання (active learning) у поєднанні з напівконтрольованим навчанням (semi-supervised learning), який базується на новій метриці — **Temporal Output Discrepancy (TOD)**.

Сучасні моделі глибокого навчання потребують великих обсягів анотованих даних, створення яких є дорогим і трудомістким процесом. Активне навчання спрямоване на зменшення витрат шляхом вибору невеликої кількості найбільш інформативних зразків для анотації. Традиційні підходи до активного навчання поділяються на два типи:

Diversity-aware: обирають різноманітні зразки, які репрезентують розподіл даних.

Uncertainty-aware: обирають зразки з високою невизначеністю моделі.

Однак ці методи часто є задачно-специфічними або потребують додаткових складних моделей, таких як модулі передбачення втрат чи змагальні мережі. Автори статті пропонують нову метрику — TOD, яка оцінює втрати зразка без необхідності доступу до міток, що робить метод простим, ефективним і універсальним.

Основна ідея статті полягає в тому, що зразки з вищими втратами (loss) є більш інформативними для навчання моделі. TOD вимірює потенційні втрати зразка, оцінюючи розбіжність (discrepancy) між виходами моделі на різних етапах оптимізації. Формально, для зразка $x \in \mathbb{R}^d$, **TOD** визначається як:

$$D_t^{(T)}(x) = ||f(x; w_{t+T}) - f(x; w_t)||$$

де:

$f(x; w_t)$ — вихід моделі з параметрами w_t на ітерації t ,

w_{t+T} — параметри моделі після T кроків градієнтного спуску,

$\|\cdot\|$ — норма L_2 .

TOD оцінює, наскільки сильно змінюється вихід моделі для певного зразка між двома моментами часу. Більша розбіжність вказує на більші втрати, що робить такі зразки цінними для анотації.

Автори доводять, що TOD є нижньою межею накопичених втрат зразка. Згідно з Теоремою 1:

$$D_t^{(1)}(x) \leq \eta \sqrt{2L_t(x) \|\nabla_w f(x; w_t)\|^2}$$

де $L_t(x) = \frac{1}{2}(y - f(x; w_t))^2$ — втрата зразка, η — швидкість навчання, а $\nabla_w f(x; w_t)$ — градієнт моделі. Для T -крокової розбіжності виводиться Корулар 2:

$$D_t^{(T)}(x) \leq \sqrt{2T\eta C} \sqrt{\sum_{\tau=t}^{t+T-1} L_\tau(x)}$$

де C — константа, що обмежує норму градієнта. Це підтверджує, що TOD корелює з втратами зразка, дозволяючи ефективно вибирати інформативні зразки.

Метод складається з двох основних компонентів: стратегії вибору даних і напівконтрольованого навчання моделі.

Для активного вибору зразків автори вводять **Cyclic Output Discrepancy (COD)**, яка є варіантом TOD, адаптованим до циклів активного навчання. COD вимірює розбіжність між виходами моделі після двох послідовних циклів:

$$D_{\text{Cyclic}}(x|w_c, w_{c-1}) = \|f(x; w_c) - f(x; w_{c-1})\|$$

де w_c і w_{c-1} — параметри моделі після c -го та $(c - 1)$ -го циклів. Зразки з найбільшими значеннями COD обираються для анотації, оскільки вони мають найбільші втрати і є найбільш інформативними.




Рисунок 1 – процес вибору даних

Опис: З немаркованого пулу X_u обираються зразки з найбільшими значеннями COD, які анотуються оракулом і додаються до маркованого пулу X_s .

Експерименти (рисунок 2) показують, що COD корелює з реальними втратами, підтверджуючи його ефективність для вибору зразків.




Рисунок 2 – Результати експериментів

Для використання немаркованих даних автори додають до цільової функції втрат **безконтрольний член**, заснований на TOD. Щоб уникнути

нестабільності, вони використовують базову модель із параметрами, отриманими через експоненційне ковзне середнє (EMA):

$$\bar{w} \leftarrow \alpha \cdot \bar{w} + (1 - \alpha) \cdot w$$

де $\alpha = 0.999$ — коефіцієнт згладжування.

Безконтрольні втрати для немаркованих даних у c -му циклі визначаються як:

$$L_U^c(w) = \frac{1}{|X_U^c|} \sum_{x_U \in X_U^c} \|f(x_U; w) - f(x_U; \bar{w})\|^2$$

Для маркованих даних використовується стандартна втрата, наприклад, крос-ентропія:

$$L_S^c(w) = \frac{1}{|X_S^c|} \sum_{(x_S, y_S) \in (X_S^c, Y_S^c)} \text{CE}[f(x_S; w), y_S]$$

Загальна цільова функція поєднує обидва члени:

$$L_{\text{overall}}^c(w) = L_S^c(w) + \lambda \cdot L_U^c(w)$$

де $\lambda = 0.05$ — ваговий коефіцієнт.




Рисунок 3 – схема напівконтрольованого навчання

Опис: Для маркованих даних модель оптимізується за допомогою втрат задачі, а для немаркованих — мінімізується відстань між виходами поточної та базової моделей.

1.2. Активний напівконтрольований випадковий ліс для класифікації гіперспектральних зображень

Стаття, опублікована в журналі Remote Sensing у 2019 році, пропонує інноваційний метод класифікації гіперспектральних зображень (HSI) під назвою **Active Semi-Supervised Random Forest (ASSRF)**. Автори, Youqiang Zhang та інші, зосередилися на вирішенні проблеми обмеженої кількості позначених даних, яка часто виникає при обробці HSI. Метод інтегрує активне навчання (Active Learning, AL) та напівконтрольоване навчання (Semi-Supervised Learning, SSL) у класифікатор Random Forest (RF), що дозволяє досягти високої точності класифікації з мінімальною кількістю вручну позначених зразків. У статті представлено нову функцію запиту для AL, яка враховує спектрально-просторову інформацію, та стратегії псевдомаркування для SSL, що уникають зміщення даних.

Метод ASSRF має на меті:

1. Використовувати мінімальну кількість вручну позначених зразків для навчання класифікатора.
2. Поєднати AL і SSL для підвищення узагальнюючої здатності моделі.
3. Враховувати спектрально-просторову інформацію для вибору інформативних зразків.
4. Зменшити зміщення, спричинене вибіркою зразків у процесі AL.

І базується на **трьох ключових компонентах**:

1. Нова функція запиту для активного навчання (DUSC): використовується для вибору найбільш інформативних і різноманітних зразків для ручного маркування.
2. Контрольоване кластерне групування: дозволяє досліджувати структуру даних і розділяти їх на зразки для AL та псевдомаркування.

3. Стратегія псевдомаркування: призначає псевдомітки зразкам із високою впевненістю класифікації, щоб збалансувати розподіл позначених даних.

Для активного навчання розроблено нову функцію запиту **Decision Uncertainty with Spectral-Spatial Constraint (DUSSC)**, яка враховує як невизначеність класифікації, так і спектрально-просторову інформацію. Формула DUSSC має вигляд:

$$f(\mathbf{x}) = - \sum_{i=1}^K p_i(\mathbf{x}) \log(p_i(\mathbf{x})) + \beta \left(\frac{1}{N} \sum_{j=1}^N \text{SID}(\mathbf{x}, \mathbf{x}_{n_j}) \right)$$

Перший член $f_1(\mathbf{x}) = - \sum_{i=1}^K p_i(\mathbf{x}) \log(p_i(\mathbf{x}))$: Це ентропія, яка вимірює невизначеність класифікації зразка $\mathbf{x}$. Чим більш рівномірний розподіл ймовірностей $p_i(\mathbf{x})$ для класів, тим вища невизначеність, і тим більш інформативним вважається зразок.

Другий член $f_2(\mathbf{x}) = \frac{1}{N} \sum_{j=1}^N \text{SID}(\mathbf{x}, \mathbf{x}_{n_j})$: Враховує спектрально-просторову схожість між зразком $\mathbf{x}$ та його просторовими сусідами $\mathbf{x}_{n_j}$. Для оцінки схожості використовується Spectral Information Divergence (SID):

$$\text{SID}(\mathbf{x}_i, \mathbf{x}_j) = \sum_{m=1}^M r_m \log \left(\frac{r_m}{s_m} \right) + \sum_{m=1}^M s_m \log \left(\frac{s_m}{r_m} \right)$$

де $r_m = \frac{\mathbf{x}_{im}}{\sum_{l=1}^M \mathbf{x}_{il}}$, $s_m = \frac{\mathbf{x}_{jm}}{\sum_{l=1}^M \mathbf{x}_{jl}}$, а M — кількість спектральних каналів.

Велике значення SID вказує на низьку схожість, що означає, що зразок може лежати на просторових межах, що робить його цінним для маркування.

Параметр β : Контролює вагу спектрально-просторового обмеження. Оптимальне значення лежить у діапазоні від 0.35 до 0.55.

Ця функція дозволяє вибирати зразки, які є не лише невизначеними, але й різноманітними в просторовому контексті, що зменшує надмірність у виборі.

Для дослідження структури даних використовується контрольований k -means алгоритм. Цей метод розбиває дані D (що містять позначені L та непозначені U зразки) на k кластерів, де k відповідає кількості класів у L . Алгоритм працює наступним чином:

1. Дані D кластеризуються на k кластерів за допомогою стандартного k -means.
2. Кожен кластер D_k аналізується:
 - a. Якщо кластер не містить позначених зразків або всі позначені зразки належать одному класу, кластеризація зупиняється.
 - b. Якщо кластер містить позначені зразки різних класів, він поділяється на k' підкластерів, де k' — кількість класів у цьому кластері.
3. Процес повторюється, доки всі кластери не стануть "чистими" (містять зразки одного класу або не містять позначених зразків).

Кластери без позначених зразків додаються до пулу кандидатів для AL , а зразки з кластерів із позначеними зразками перевіряються класифікатором RF . Ті, що мають високу впевненість класифікації, отримують псевдомітки, а інші додаються до пулу для AL .

Щоб уникнути зміщення, спричиненого фокусом AL на зразках із високою невизначеністю, ASSRF призначає псевдомітки зразкам із високою впевненістю класифікації. Процес включає:

1. Навчання тимчасового класифікатора RF ($r f_m$) на позначених даних L .
2. Класифікація зразків із кластерів, що містять позначені зразки (C_1).

3. Призначення псевдоміток g зразкам із найвищою впевненістю, які додаються до набору P .
4. Решта зразків ($R = C_1 \setminus P$) додаються до пулу кандидатів для AL.

Цей підхід забезпечує збалансованіший розподіл позначених даних, що сприяє стабільності моделі.

Алгоритм ASSRF — це ітеративний метод, який поєднує AL і SSL у єдиній структурі. Основні етапи алгоритму:

1. Ініціалізація:
 - 1.1. Початкові позначені дані L , порожні набори для псевдоміток P та вручну позначених зразків M .
 - 1.2. Навчання RF на L .
2. Кластеризація:
 - 2.1. Розбиття непозначених даних U на кластери за допомогою контрольованого k -means (Algorithm 1).
 - 2.2. Кластери поділяються на C_1 (з позначеними зразками) та C_2 (без позначених зразків).
3. Перевірка:
 - 3.1. Навчання тимчасового RF (r^f_m) на L .
 - 3.2. Класифікація зразків у C_1 , призначення псевдоміток g зразкам із високою впевненістю.
4. Активне навчання:
 - 4.1. Формування пулу кандидатів $S = C_2 \cup R$.
 - 4.2. Використання DUSC для вибору h зразків для ручного маркування, які додаються до M .
5. Напівконтрольоване навчання:
 - 5.1. Оновлення $L = L \cup P \cup M$, $U = U \setminus L$.
 - 5.2. Класифікація решти зразків у $O = S \setminus M$ за допомогою RF для отримання ймовірностей $p(k|\mathbf{x})$.

5.3. Обчислення маржі для кожного зразка в O за формулою:

$$g_k(\mathbf{x}_u) = \frac{1}{1 + \exp(-p(k|\mathbf{x}_u))}$$

5.4. Обчислення оптимального розподілу ймовірностей за допомогою детермінованого відпалу (Deterministic Annealing, DA):

$$\hat{p}^*(k|\mathbf{x}_u) = \frac{\exp\left(\frac{-\alpha l(g_k(\mathbf{x}_u)) + T}{T}\right)}{Z(\mathbf{x}_u)}$$

де $Z(\mathbf{x}_u)$ — нормувальна константа, α — внесок непозначених даних, T — температура.

6. Оновлення RF:

6.1. Призначення випадкових міток зразкам у O на основі $\hat{p}^*(k|\mathbf{x}_u)$.

6.2. Повторне навчання дерев RF на даних $L \cup O$.

7. Повторення:

7.1. Цикл повторюється до досягнення заданого числа ітерацій.

РОЗДІЛ 2. ІНТЕГРАЦІЯ TOD/COD З ASSRF ДЛЯ КЛАСИФІКАЦІЇ ГІПЕРСПЕКТРАЛЬНИХ ЗОБРАЖЕНЬ

Розглянемо детально кожен крок в повному алгоритмі на прикладі датасету KSC.

1. Завантаження даних. На цьому етапі код завантажує гіперспектральні дані з файлів KSC.mat (вхідні ознаки `X_full`) та KSC_gt.mat (мітки `y_full`) за допомогою функції `loadmat` із бібліотеки `scipy.io`. Ці дані представляють зображення з набору Kennedy Space Center (KSC), де `X_full` містить спектральні канали, а `y_full` — мітки класів. Дані передаються в блок попередньої обробки для трансформації перед аналізом.

2. Попередня обробка даних. Дані трансформуються для зручності обробки. `X_full` перетворюється з 3D масиву в 2D (`X = X_full.reshape(-1, X_full.shape[-1])`), де кожен рядок відповідає пікселю з усіма спектральними каналами. Мітки `y_full` розгортаються в 1D масив (`y = y_full.ravel()`). Фільтрується маска (`mask = y > 0`), щоб виключити непозначені пікселі, а мітки коригуються (`y = y[mask] - 1`), щоб класи починалися з 0. Оброблені дані передаються в блок розподілу для поділу на підмножини.

3. Розподіл даних. Дані діляться на три підмножини: позначені (`labeled_idx`), непозначені (`unlabeled_idx`) і тестові (`test_idx`). Для кожного класу випадково вибирається 10 позначених прикладів (`labeled_idx`), решта стають непозначеними. Тестовий набір формується шляхом випадкового вибору 40% даних, що не входять до позначених (`test_idx`). Позначені та непозначені дані використовуються в циклі навчання, а тестовий набір — для оцінки.

4. Ініціалізація. Ініціалізуються моделі та параметри. Створюється `RandomForestClassifier` з 500 деревами, `KMeans` з 13 кластерами, а також параметри активного навчання: кількість ітерацій (`n_iters=50`), розмір партій для активного вибору (`active_batch=10`) і псевдомаркерів (`pseudo_batch=10`), параметри ЕМА (`ema_decay=0.999`), вага для непозначених даних (`lambda_unsup=0.05`), поріг впевненості (`confidence_threshold=0.95`),

температура ($\text{temp}=1.0$, $\text{temp_min}=0.5$, $\text{temp_decay}=0.95$). Також ініціалізується масив для попередніх ймовірностей (prev_proba) та виконується кластеризація непозначених даних ($\text{KMeans.fit_predict}$). Моделі та параметри використовуються в циклі навчання.

5. Початок циклу ($\text{epoch}=1$ до n_iters). Починається ітеративний процес активного навчання, який повторюється n_iters разів. Кожна ітерація включає навчання моделі, оцінку прикладів і оновлення наборів даних. Об'єднує всі наступні блоки циклу.

6. Навчання Random Forest. Модель Random Forest навчається на поточному наборі позначених даних ($X[\text{labeled_idx}]$, $y[\text{labeled_idx}]$). Навчена модель використовується для обчислення ймовірностей у наступному блоці.

7. Обчислення ймовірностей (proba). Random Forest передбачає ймовірності класів для всіх даних ($\text{proba} = \text{rf.predict_proba}(X)$). Ймовірності використовуються для ЕМА, обчислення метрик і вибору прикладів.

8. Оновлення ЕМА proba . Експоненціально зважене середнє ймовірностей (ema_proba) оновлюється за формулою $\text{ema_proba} = \text{ema_decay} * \text{ema_proba} + (1 - \text{ema_decay}) * \text{proba}$. На першій ітерації ema_proba ініціалізується копією proba . Далі ema_proba використовується для обчислення TOD у блоці метрик.

9. Обчислення метрик. Обчислюються чотири метрики для непозначених даних:

ентропія: вимірює невизначеність передбачень.

COD (Change of Distribution): норма різниці між поточними та попередніми ймовірностями, якщо не перша ітерація.

TOD (Temporal Output Discrepancy): квадратична різниця між proba і ema_proba .

Кластерні оцінки: середня ентропія для кожного кластера KMeans (cluster_scores).

10. Комбінація оцінок. Метрики об'єднуються в єдину оцінку (combined_score) за формулою:

На першій ітерації: $0.7 * \text{entropy} + 0.2 * \text{cluster_scores} + 0.1 * \text{cod_score}$.

На наступних ітераціях: $0.7 * \text{entropy} + 0.1 * \text{cluster_scores} + 0.1 * \text{cod_score} + 0.1 * \text{tod_score}$. В подальшому `combined_score` використовується для вибору активних прикладів.

11. Вибір активних прикладів. Вибираються `active_batch` непозначених прикладів із найвищими значеннями `combined_score`. В подальшому `active_idx` додається до `labeled_idx` у блоці оновлення.

12. Вибір псевдомаркерів. Вибираються `pseudo_batch` непозначених прикладів із найвищими значеннями впевненості, а їхні мітки визначаються як `pseudo_labels`. Далі `pseudo_idx` і `pseudo_labels` додаються до `labeled_idx` і `y`.

13. Оновлення наборів. Оновлюються набори даних: `labeled_idx` додаються `active_idx` і `pseudo_idx`, `unlabeled_idx` оновлюється шляхом видалення використаних прикладів, а `y[pseudo_idx]` присвоюються псевдомітки. Оновлені набори використовуються в наступній ітерації.

14. Оновлення параметрів. Оновлюються параметри `temp` (зменшується до `temp_min` із коефіцієнтом `temp_decay`) і `confidence_threshold` (зменшується до мінімуму 0.7 із коефіцієнтом 0.95). Також зберігається `prev_proba` для наступної ітерації. Оновлені параметри впливають на вибір псевдомаркерів у наступній ітерації.

15. Оцінка на тестовому наборі. Модель передбачає мітки для тестового набору (`y_pred_test = rf.predict(X_test)`), і обчислюється загальна точність (`accuracy_score`). Результати виводяться для моніторингу, але не впливають на цикл.

16. Кінець циклу. Перевіряється, чи досягнуто `n_iters`. Якщо ні, цикл повертається до блоку навчання Random Forest.


17. Фінальне навчання Random Forest. Після завершення циклу Random Forest навчається остаточно на всіх позначених даних. Модель використовується для фінальних передбачень.

18. Фінальні передбачення. Обчислюються фінальні ймовірності та передбачення. Передбачення використовуються для оцінки та візуалізації.

19. Оцінка результатів. Обчислюється фінальна точність на тестовому наборі (`accuracy_score`) та виводиться звіт класифікації (`classification_report`).
Результати виводяться разом із візуалізацією.

20. Візуалізація. Створюються три візуалізації:
RGB-зображення даних (`show_rgb_composite`).
Мапа справжніх міток (`show_label_map` для `y`).
Мапа передбачених міток (`show_label_map` для `final_preds`).
Матриця плутанини (`plot_conf_matrix`).

Зобразимо основний цикл на схемі.



Розберемо деталі модифікацій, наданих у нашій програмі.

Додано TOD як новий критерій для оцінки втрат непозначених зразків, що запозичено з іншої статті (Huang et al., ICCV). TOD вимірює розбіжність між поточними ймовірностями (proba) і експоненційно згладженими ймовірностями (ema_proba):

$$\text{tod_score}_i = \sum_{k=1}^K (\text{proba}_i[k] - \text{ema_proba}_i[k])^2$$

де proba – поточні ймовірності;

ema_proba – експоненційно згладжені ймовірності.

Також введено COD як додаткову оцінку для активного навчання, яка вимірює L2-норму різниці між ймовірностями поточної та попередньої ітерацій:

$$\text{cod_score}_i = \|\text{proba}_i - \text{prev_proba}_i\|_2$$

де proba – поточна ітерація;

prev_proba – попередня ітерація

На першій ітерації COD замінюється ентропією, але з другої ітерації він додається до комбінованої оцінки.

Обчислюється безконтрольна втрата TOD, як середня квадратична різниця між proba і ema_proba для непозначених зразків:

$$\text{unsup_loss} = \frac{1}{|U|} \sum_{i \in U} \sum_{k=1}^K (\text{proba}_i[k] - \text{ema_proba}_i[k])^2$$

Ця втрата виводиться для моніторингу, але не впливає безпосередньо на тренування RF (оскільки RF не оптимізується градієнтним спуском, як у нейронних мережах).

Запроваджено нову комбіновану оцінку (combined_score) для вибору зразків, яка є більш багатокomпонентною:

На першій ітерації:

$$\text{combined_score} = 0.7 \cdot \text{entropy} + 0.2 \cdot \text{cluster_scores} + 0.1 \cdot \text{cod_score}$$

На наступних ітераціях:

$$\text{combined_score} = 0.7 \cdot \text{entropy} + 0.1 \cdot \text{cluster_scores} + 0.1 \cdot \text{cod_score} + 0.1 \cdot \text{tod_score}$$

У новій оцінці ентропія залишається основним компонентом (вага 0.7), як і в DUSSC, для оцінки невпевненості.

Додано оцінку на основі середньої ентропії зразків у кластерах (K-means, n_clusters=13), що враховує розподіл даних. Це замінює просторово-спектральне обмеження DUSSC, яке було більш специфічним для HSI.

Використовується не супервізійне кластерування (K-means із n_clusters=13) лише для непозначених зразків, без урахування позначених даних. Для реалізації кластери формуються один раз на початку (kmeans.fit_predict(X[unlabeled_idx])) і оновлюються лише для відповідності зменшеному набору непозначених зразків.

Для кожного кластера обчислюється середня ентропія зразків, яка додається до combined_score як cluster_scores.

Отже, в нашій модифікації кластерування не розділяє кластери на основі наявності позначених зразків, а використовується для оцінки різноманітності даних у комбінованій оцінці. Псевдомаркування не залежить від кластерів, а базується виключно на впевненості моделі (confidences).

Додане температурне масштабування, саме: впевненість для псевдомаркування обчислюється з масштабуванням ймовірностей через температуру (temp):

$$\text{confidences}_i = \max_k \left(\frac{\text{proba}_i[k]}{\text{temp}} \right)$$

Температура зменшується від 1.0 до 0.5 із коефіцієнтом 0.95, що робить відбір зразків більш консервативним на пізніх ітераціях. Використовується динамічний поріг впевненості (confidence_threshold) зменшується з 0.95 до щонайменше 0.7 із коефіцієнтом 0.95, що дозволяє адаптувати критерії псевдомаркування.

РОЗДІЛ 3. ОПИС ТА АНАЛІЗ ОТРИМАННИХ РЕЗУЛЬТАТІВ

У цьому дослідженні для оцінки ефективності запропонованого підходу TOD/COD-ASSRF були використані два загальновизнаних набори гіперспектральних даних: Botswana та Kennedy Space Center (KSC). Обидва набори даних представляють складні сцени з різноманітними типами земного покриття та рослинності, що робить їх ідеальними для тестування алгоритмів класифікації.

3.1. Набір даних Botswana

Набір даних Botswana був отриманий за допомогою гіперспектрального сенсора Hyperion, встановленого на супутнику EO-1 (Earth Observing-1) NASA, 31 травня 2001 року. Сцена охоплює частину дельти річки Окаванго в Ботсвані, яка є найбільшою внутрішньоконтинентальною дельтою у світі і характеризується різноманітними водно-болотними екосистемами.

Botswana RGB Composite



Рисунок 4 – RGB-комполит набору даних Botswana, створений з використанням каналів 30 (червоний), 20 (зелений) і 10 (синій)

Технічні характеристики:

- Просторове розрішення: 30 м на піксель
- Спектральний діапазон: 400-2500 нм
- Спектральне розрішення: 10 нм

- Загальна кількість каналів: 242
- Використовувані канали: 145
- Розмір зображення: 1476×256 пікселів

Класи земного покриву:

1. Вода (Water)
2. Заплавна рослинність 1 (Hippo grass)
3. Заплавна рослинність 2 (Papyrus)
4. Заплавна рослинність 3 (Reeds)
5. Заплавні луки 1 (Floodplain grasses 1)
6. Заплавні луки 2 (Floodplain grasses 2)
7. Острівна рослинність (Island vegetation)
8. Акація (Acacia woodlands)
9. Акація саван (Acacia shrublands)
10. Акація луків (Acacia grasslands)
11. Короткі міомбо (Short mopane)
12. Змішані міомбо (Mixed mopane)
13. Відкриті луки (Exposed soils)
14. Вогнища (Fire scars)

Особливу складність для класифікації становлять класи заплавної рослинності (2-4) та заплавних луків (5-6), які мають схожі спектральні сигнатури через подібний біохімічний склад і умови зростання. Також класи акації (8-10) характеризуються значним спектральним перекриттям.

3.2. Набір даних Kennedy Space Center (KSC)

Набір даних Kennedy Space Center був отриманий за допомогою авіаційного спектрометра AVIRIS (Airborne Visible/Infrared Imaging Spectrometer) NASA під час польоту над територією Космічного центру імені Кеннеді у Флориді, США, 23 березня 1996 року. Дана територія

характеризується різноманітними прибережними екосистемами, включаючи різні типи водно-болотних угідь, лісів та саван.

Технічні характеристики:

- Просторове розрішення: 18 м на піксель
- Спектральний діапазон: 400-2500 нм
- Спектральне розрішення: 10 нм
- Загальна кількість каналів: 224
- Використовувані канали: 176 (після видалення шумових каналів)
- Розмір зображення: 512 × 614 пікселів

Класи земного покриву:

1. Мангрові зарості (Scrub)
2. Вільховий ліс (Willow swamp)
3. Кипарисовий/дубовий ліс (CP hammock)
4. Капустяно-пальмовий/дубовий ліс (CP/Oak hammock)
5. Слеш-соснові зарості (Slash pine)
6. Дубовий/широколистий ліс (Oak/Broadleaf hammock)
7. Вільхове болото (Hardwood swamp)
8. Луговина (Graminoid marsh)
9. Спартина-марш (Spartina marsh)
10. Хвощове болото (Cattail marsh)
11. Солончаковий болото (Salt marsh)
12. Мулистий-солончаковий болото (Mud flats)
13. Вода (Water)

Набір даних KSC характеризується значною спектральною схожістю між деякими класами, особливо між різними типами болотних екосистем (класи 9-12). Також спостерігається значна внутрішньокласова варіативність для класів лісових масивів (2-6) через різний вік дерев, щільність крон та підлісок.

KSC RGB Composite



Рисунок 5 – RGB-композиція набору даних Kennedy Space Center, створений з використанням каналів 30 (червоний), 20 (зелений) і 10 (синій)

3.3. Результати на наборі даних Botswana

3.3.1 Базові методи класифікації

Для встановлення базової продуктивності було проведено експерименти з використанням стандартного алгоритму Random Forest (RF) у двох конфігураціях:

1. RF₁ (мінімальна кількість маркованих даних):
 - a. Використано по 10 випадково вибраних пікселів для кожного з 14 класів
 - b. Загальна кількість маркованих зразків: 140 (приблизно 4.3% від загальної кількості маркованих пікселів)
 - c. Параметри: 500 дерев, максимальна глибина без обмежень, критерій розщеплення - індекс Джині
2. RF₂ (збільшена кількість маркованих даних):

- a. Використано по 10 пікселів для кожного класу + додаткові 500 випадково вибраних пікселів
- b. Загальна кількість маркованих зразків: 640 (приблизно 19.7% від загальної кількості маркованих пікселів)
- c. Ті ж параметри, що і для RF₁

Результати класифікації базовими методами:

- RF₁ (140 маркованих зразків): Overall Accuracy = 76.72%
- RF₂ (640 маркованих зразків): Overall Accuracy = 86.94%

Покращення точності на 10.22% при використанні додаткових 500 зразків підтверджує значний вплив обсягу маркованих даних на точність класифікації навіть для потужного ансамблевого алгоритму, такого як Random Forest. Однак у реальних сценаріях маркування додаткових 500 зразків вимагає значних часових та експертних ресурсів.

3.3.2 Продуктивність TOD/COD-ASSRF

Запропонований алгоритм TOD/COD-ASSRF був ініціалізований з тою ж мінімальною кількістю маркованих даних, що й RF₁ (10 пікселів на клас, всього 140 зразків). Навчання проводилося протягом 50 ітерацій з наступними параметрами:

- Розмір партії для активного вибору: 10 зразків на ітерацію
- Розмір партії для псевдомаркування: 10 зразків на ітерацію
- Коефіцієнт згасання ЕМА: 0.999
- Початкова температура: 1.0
- Коефіцієнт зменшення температури: 0.95
- Мінімальна температура: 0.5
- Початковий поріг довіри: 0.98




Рисунок 6 – Графік зміни Overall Accuracy та TOD loss протягом 50 ітерацій навчання для набору даних Botswana

Графік демонструє стійке зростання точності протягом ітерацій, з початкового значення близько 77% (що відповідає точності RF_1) до 95,7% на пізніх ітераціях. Значення TOD loss демонструє загальну тенденцію до зменшення, що свідчить про зростаючу стабільність прогнозів моделі, хоча спостерігаються деякі флуктуації, особливо на ранніх ітераціях

Фінальна модель, що використовує ансамблювання поточних та ЕМА-прогнозів, досягає Overall Accuracy 93.76% на тестовому наборі.




Рисунок 7 – Візуалізація справжніх міток класів (Ground Truth) для набору даних Botswana та Візуалізація прогнозованих міток класів (TOD/COD-ASSRF) для набору даних Botswana

Візуальне порівняння справжніх та прогнозованих міток класів демонструє високу точність класифікації для більшості регіонів. Найбільші розбіжності спостерігаються на межах між спектрально схожими класами, зокрема між класами заплавної рослинності (2-4) та між різними типами акації (8-10).

3.3.3 Детальний аналіз результатів класифікації

Classification Report:

	precision	recall	f1-score	support
Water	0.991	1.000	0.995	107
Hippo grass	0.829	0.971	0.895	35
Floodplain grasses 1	0.960	0.960	0.960	99
Floodplain grasses 2	1.000	1.000	1.000	79
Reeds	0.881	0.912	0.897	114
Riparian	0.762	0.816	0.788	98
Firescar	0.982	0.991	0.986	108
Island interior	1.000	0.973	0.986	75
Acacia woodlands	0.981	0.829	0.899	123
Acacia shrublands	0.930	0.877	0.903	106
Acacia grasslands	0.931	0.953	0.942	128
Short mopane	0.972	0.946	0.959	74
Mixed mopane	0.951	0.975	0.963	120
Exposed soils	0.892	1.000	0.943	33
accuracy			0.936	1299
macro avg	0.933	0.943	0.937	1299
weighted avg	0.939	0.936	0.936	1299

Рисунок 8 – Детальний звіт класифікації надає глибоке розуміння ефективності алгоритму TOD/COD-ASSRF для кожного класу набору даних Botswana




Рисунок 9 – Матриця помилок (Confusion Matrix) для набору даних Botswana

Аналіз результатів виявляє наступні закономірності:

1. Класи з відмінною продуктивністю:

- a. Water (Вода): precision 0.991, recall 1.000, f1-score 0.995.
Практично ідеальна класифікація водних об'єктів, що пояснюється їх чіткими спектральними характеристиками, значно відмінними від рослинного покриву.
- b. Floodplain grasses 2 (Заплавні луки 2): precision 1.000, recall 1.000, f1-score 1.000. Абсолютно ідеальна класифікація, що свідчить про унікальні спектральні характеристики цього типу заплавних луків.
- c. Island interior (Острівна рослинність): precision 1.000, recall 0.973, f1-score 0.986. Надзвичайно висока точність класифікації острівної рослинності, з лише кількома пропущеними зразками.
- d. Firescar (Вогнища): precision 0.982, recall 0.991, f1-score 0.986.
Ефективне розпізнавання територій, пошкоджених пожежами, що, ймовірно, мають унікальні спектральні відбитки.

2. Класи з хорошою продуктивністю:

- a. Floodplain grasses 1 (Заплавні луки 1): precision 0.960, recall 0.960, f1-score 0.960. Хороша збалансована класифікація першого типу заплавних луків.
- b. Mixed mopane (Змішані міомбо): precision 0.951, recall 0.975, f1-score 0.963. Ефективне розпізнавання цього типу рослинності з незначною кількістю помилок.
- c. Short mopane (Короткі міомбо): precision 0.972, recall 0.946, f1-score 0.959. Висока точність класифікації з невеликою кількістю пропущених зразків.

3. Класи з помірною продуктивністю:

- a. Acacia grasslands (Акація луків): precision 0.931, recall 0.953, f1-score 0.942.
- b. Acacia shrublands (Акація саван): precision 0.930, recall 0.877, f1-score 0.903.
- c. Exposed soils (Відкриті ґрунти): precision 0.892, recall 1.000, f1-score 0.943. Цікавий випадок, коли всі зразки класу виявлені (ідеальний recall), але є деякі помилкові спрацьовування.

4. Проблемні класи:

- a. Riparian (Прибережна рослинність): precision 0.762, recall 0.816, f1-score 0.788. Найнижчі показники серед усіх класів, що свідчить про складність розпізнавання цього типу рослинності.
- b. Hippo grass (Гіпопотамова трава): precision 0.829, recall 0.971, f1-score 0.895. Незважаючи на високий recall, відносно низька precision вказує на тенденцію алгоритму хибно класифікувати інші класи як Hippo grass.
- c. Acacia woodlands (Акація лісів): precision 0.981, recall 0.829, f1-score 0.899. Висока precision, але низький recall свідчить про те, що модель пропускає значну частину зразків цього класу.

Загалом, розподіл помилок класифікації має екологічно обґрунтований характер, де найбільше плутаються класи з подібними умовами зростання та біохімічним складом, що призводить до схожих спектральних характеристик.

Аналіз співвідношення між кількістю тестових зразків (support) та точністю класифікації не виявляє чіткої кореляції. Наприклад, Exposed soils (Відкриті ґрунти) має найменшу кількість тестових зразків (33), але демонструє високий f1-score (0.943), тоді як Riparian (Прибережна рослинність) має значно більше зразків (98), але найнижчий f1-score (0.788).

Порівняння з базовими методами демонструє значне покращення:

- Загальна точність TOD/COD-ASSRF (93.6%) на 16.89% вища за RF₁ (76.72%)
- Покращення на 6.67% порівняно з RF₂ (86.94%), який використовує значно більшу кількість заздалегідь маркованих зразків

Full Image Predictions




Рисунок 10 – класифікація на повному наборі даних

Також була проведена класифікація на повному наборі даних Botswana. Результати демонструють надзвичайно високу точність запропонованого методу TOD/COD-ASSRF, що досягає загального показника Overall Accuracy

95.26%. На зображенні чітко відображається складна мозаїка різноманітних типів рослинності дельти Окаванго з характерними екологічними градієнтами. Особливо виразно виділяються водні об'єкти (темно-зелений колір), різні типи акацієвих угруповань (рожевий, зелений та коричневий кольори) у верхній частині зображення, заплавна рослинність (світло-блакитний та червоний кольори) та прибережні зони (жовтий колір) у середній та нижній частинах. Модель успішно розрізняє навіть спектрально схожі класи, такі як різні типи заплавних луків (Floodplain grasses) та різні види акацієвих угруповань, досягаючи для більшості класів показників f1-score вище 0.95. Лише для класу "Riparian" спостерігається відносно нижча точність (precision 0.755), що узгоджується з раніше виявленими закономірностями та пояснюється схожістю спектральних характеристик з іншими типами прибережної рослинності.

Отримані результати підтверджують ефективність запропонованого підходу TOD/COD-ASSRF для класифікації різноманітних типів рослинності та земного покриття в складному ландшафті дельти Окаванго. Особливо важливо, що метод демонструє високу точність навіть для спектрально схожих класів, які традиційно є проблематичними для класифікації гіперспектральних зображень.

3.4. Результати на наборі даних Kennedy Space Center

3.4.1. Базові методи класифікації

Для набору даних Kennedy Space Center, як і для Botswana, спочатку були проведені експерименти з використанням базового алгоритму Random Forest у двох конфігураціях:

1. RF₁ (мінімальна кількість маркованих даних):
 - 1.1. Використано по 10 випадково вибраних пікселів для кожного з 13 класів
 - 1.2. Загальна кількість маркованих зразків: 130 (приблизно 2.5% від загальної кількості)

2. RF₂ (збільшена кількість маркованих даних):
 - 2.1. Використано по 10 пікселів для кожного класу + додаткові 500 випадково вибраних пікселів
 - 2.2. Загальна кількість маркованих зразків: 630 (приблизно 12.1% від загальної кількості)

Результати класифікації базовими методами:

1. RF₁ (130 маркованих зразків): Overall Accuracy = 80.95%
2. RF₂ (630 маркованих зразків): Overall Accuracy = 87.80%

Результати показують, що додавання 500 маркованих зразків покращує точність класифікації на 6.85%. Варто відзначити, що базова точність RF₁ для KSC (80.95%) вища, ніж відповідний показник для Botswana (76.72%), незважаючи на меншу відносну кількість початкових маркованих даних. Це може свідчити про те, що деякі класи в наборі даних KSC мають більш виражені спектральні відмінності.

3.4.2 Продуктивність TOD/COD-ASSRF

Запропонований алгоритм TOD/COD-ASSRF був ініціалізований з такою ж мінімальною кількістю маркованих даних, як і RF₁ (10 пікселів на клас, всього 130 зразків), та навчався протягом 50 ітерацій з параметрами, ідентичними експериментам на наборі Botswana.

Фінальні результати на тестовому наборі: TOD/COD-ASSRF: Overall Accuracy = 91.89%




Рисунок 11 – Графік зміни Overall Accuracy та TOD loss протягом 50 ітерацій навчання для набору даних KSC

Це покращення більш ніж на 10% порівняно з RF_1 (80.95%) і більш ніж на 3% порівняно з RF_2 (87.80%), демонструючи ефективність запропонованого підходу. Заключна точність на останній ітерації становила 91.79%, що дуже близько до фінального значення після ансамблювання.

3.4.3. Детальний аналіз результатів класифікації

Classification Report:

	precision	recall	f1-score	support
Scrub	0.940	0.969	0.954	321
Willow swamp	0.980	0.950	0.965	101
CP hammock	0.963	0.876	0.918	89
CP/Oak hammock	0.865	0.822	0.843	101
Slash pine	0.902	0.836	0.868	55
Oak/Broadleaf hammock	0.707	0.707	0.707	82
Hardwood swamp	0.870	0.952	0.909	42
Graminoid marsh	0.903	0.846	0.874	188
Spartina marsh	0.958	0.948	0.953	193
Cattail marsh	1.000	0.715	0.834	158
Salt marsh	0.988	0.982	0.985	169
Mud flats	0.750	0.950	0.838	218
Water	0.973	0.995	0.984	367
accuracy			0.914	2084
macro avg	0.908	0.888	0.895	2084
weighted avg	0.920	0.914	0.914	2084

Рисунок 12 – детальний звіт класифікації для набору даних KSC




Рисунок 13 – Матриця помилок (Confusion Matrix) для набору даних KSC

Аналіз результатів виявляє наступні закономірності:

1. Класи з відмінною продуктивністю:

- a. Water (Вода): precision 0.973, recall 0.995, f1-score 0.984. Надзвичайно висока точність класифікації водних об'єктів, що є очікуваним, враховуючи унікальні спектральні характеристики води.
- b. Salt marsh (Солончакове болото): precision 0.988, recall 0.982, f1-score 0.985. Найвищий f1-score серед усіх класів, демонструє ефективне розпізнавання цього типу болотистої рослинності.
- c. Willow swamp (Вільхове болото): precision 0.980, recall 0.950, f1-score 0.965. Дуже висока точність класифікації, незважаючи на схожість з іншими типами заболочених лісів.
- d. Scrub (Мангрові зарості): precision 0.940, recall 0.969, f1-score 0.954. Стабільно висока точність для найбільш представленого класу в тестовому наборі (321 зразок).

2. Класи з хорошою продуктивністю:

- a. Spartina marsh (Спартина-болото): precision 0.958, recall 0.948, f1-score 0.953. Збалансована висока точність для цього типу болотистої екосистеми.
- b. CP hammock (Кипарисовий/дубовий ліс): precision 0.963, recall 0.876, f1-score 0.918. Висока precision, але дещо нижчий recall свідчить про тенденцію до пропуску деяких зразків цього класу.
- c. Hardwood swamp (Вільхове болото): precision 0.870, recall 0.952, f1-score 0.909. Добре збалансована класифікація, особливо враховуючи малу кількість тестових зразків (42).

3. Класи з помірною продуктивністю:

- a. Graminoid marsh (Луговина): precision 0.903, recall 0.846, f1-score 0.874. Прийнятна точність для цього типу боліт.
- b. Slash pine (Слеш-соснові зарості): precision 0.902, recall 0.836, f1-score 0.868. Відносно хороша precision, але модель пропускає певну кількість зразків цього класу.

- c. CP/Oak hammock (Капустяно-пальмовий/дубовий ліс): precision 0.865, recall 0.822, f1-score 0.843. Помірна точність, що може бути пов'язана зі схожістю з іншими лісовими класами.

4. Проблемні класи:

- a. Oak/Broadleaf hammock (Дубовий/широколистий ліс): precision 0.707, recall 0.707, f1-score 0.707. Найнижча точність серед усіх класів, що свідчить про складність розпізнавання цього типу лісової рослинності.
- b. Cattail marsh (Хвощове болото): precision 1.000, recall 0.715, f1-score 0.834. Цікавий випадок, коли всі зразки, класифіковані як цей клас, є правильними (ідеальна precision), але модель пропускає значну частину зразків цього класу.
- c. Mud flats (Мулисті рівнини): precision 0.750, recall 0.950, f1-score 0.838. Модель має тенденцію хибно класифікувати інші класи як Mud flats, але ефективно виявляє справжні зразки цього класу.

Результати повної класифікації набору даних Kennedy Space Center, представлені на зображенні, демонструють високу ефективність запропонованого методу TOD/COD-ASSRF в умовах реального застосування. На карті чітко виділяються різні типи земного покриття: значна водна поверхня (бірюзовий колір) у центральній частині, оточена прибережною рослинністю (зелений колір - "Salt marsh"), обширні зони болотяних екосистем типу "Graminoid marsh" (пурпурний колір) у нижній частині, а також різноманітні лісові угруповання (ділянки червоного, жовтого, синього кольорів) на правій стороні зображення. Особливо добре простежуються екологічні переходи між різними типами рослинності, що відповідають природним градієнтам вологості та висоти над рівнем моря, підтверджуючи екологічну обґрунтованість отриманої класифікації. Важливо відзначити, що модель коректно визначила складні мозаїчні ділянки змішаної рослинності, демонструючи високу просторову точність класифікації навіть на

проблемних перехідних зонах. Точність на повному наборі даних склала 91.75%




Рисунок 14 – Результат класифікації на повному наборі даних KSC

Важливо відзначити, що розподіл помилок класифікації для KSC, як і для Botswana, має екологічно обґрунтований характер. Найбільше плутаються класи, що представляють екологічно подібні типи рослинності, які часто зустрічаються в одних і тих же ландшафтних зонах і мають схожий видовий склад.

Порівняння з базовими методами демонструє значне покращення:

- Покращення на 11% порівняно з RF_1 (80.95%)
- Покращення на 3.8% порівняно з RF_2 (87.80%)

Ці результати підтверджують ефективність запропонованого підходу TOD/COD-ASSRF для класифікації складних прибережних екосистем із

різноманітними типами рослинності, представленими в наборі даних Kennedy Space Center.

ВИСНОВКИ

У даній роботі розроблено та досліджено інноваційний підхід до класифікації гіперспектральних зображень в умовах обмеженої кількості маркованих даних, що інтегрує Temporal Output Discrepancy (TOD) та Cyclic Output Discrepancy (COD) з Active Semi-Supervised Random Forest (ASSRF).

Основним науковим результатом роботи є створення комплексного методу, що ефективно поєднує активне та напівконтрольоване навчання на основі аналізу розбіжностей у прогнозах моделі. Запропонований підхід вирішує фундаментальну проблему нестачі маркованих даних при класифікації гіперспектральних зображень через оптимальний вибір найбільш інформативних зразків для експертного маркування та надійне псевдомаркування немаркованих зразків.

Експериментальна верифікація на двох загальновизнаних наборах гіперспектральних даних (Botswana та Kennedy Space Center) продемонструвала значне покращення точності класифікації: TOD/COD-ASSRF досягає Overall Accuracy 94.9% для Botswana та 91.7% для KSC, перевершуючи базові підходи на 10-17% при використанні мінімальної кількості початкових маркованих даних.

Ключовою перевагою запропонованого методу є його здатність забезпечувати високу точність класифікації при значно меншій кількості маркованих даних порівняно з традиційними підходами. Це має особливу практичну цінність для широкомасштабних проектів моніторингу земного покриття, де процес маркування даних є трудомістким і дорогим.

Детальний аналіз результатів класифікації виявив, що TOD/COD-ASSRF демонструє високу ефективність для більшості класів земного покриття, з деякими обмеженнями для спектрально схожих типів рослинності. При цьому характер розподілу помилок класифікації має екологічно обґрунтований характер, що відповідає реальним взаємозв'язкам між типами рослинності.

Практична значимість роботи полягає в можливості суттєвого скорочення витрат на маркування даних при збереженні високої точності класифікації гіперспектральних зображень. Запропонований метод може бути успішно застосований у різних сферах, включаючи екологічний моніторинг, прецизійне сільське господарство, управління лісовими ресурсами та відстеження змін земного покриву.

Перспективними напрямками подальших досліджень є:

- Інтеграція просторової інформації для покращення класифікації спектрально схожих класів
- Розробка адаптивних стратегій визначення оптимального співвідношення між активно маркованими та псевдомаркованими зразками
- Дослідження ефективності методу для інших типів даних дистанційного зондування
- Поширення підходу на задачі виявлення змін та часового моніторингу

Таким чином, запропонований підхід TOD/COD-ASSRF представляє собою ефективне рішення для однієї з ключових проблем у галузі класифікації гіперспектральних зображень і має значний потенціал для широкого практичного застосування в сфері дистанційного зондування Землі.

СПИСОК ВИКОРИСТАНИХ ДЖЕРЕЛ

1. **Semi-Supervised Active Learning with Temporal Output Discrepancy** [Електронний ресурс] — URL: <https://arxiv.org/abs/2107.14153>.
2. **Active Semi-Supervised Random Forest for Hyperspectral Image Classification** [Електронний ресурс] — URL: <https://www.mdpi.com/2072-4292/11/24/2974>.
3. **A Survey on Semi-Supervised Semantic Segmentation** [Електронний ресурс] — URL: <https://arxiv.org/abs/2302.09899>.
4. **Kennedy Space Center** [Електронний ресурс] — URL: <https://www.kaggle.com/datasets/samyabose/kennedy-space-center>.
5. **Botswana** [Електронний ресурс] — URL: <https://www.kaggle.com/datasets/mingliu123/botswana>.